

Faithfulness of the Harness：歸因 Agent 的工具選擇分歧

一、題目

LLM Agent 在不同 harness (Claude Code、Codex CLI、OpenCode、Hermes) 下的不同 tool 序列差異有多少來自 harness 設計 (system prompt、tool def、skills 調用邏輯、memory)？多少來自模型？研究在隔離環境用 4 種 xAI 方法 + 2×3 partial factorial 探討 harness、模型與交互作用的解釋。

(一) 設計取捨

1. 不納入 Antigravity CLI：5/20 才發表、harness 未成熟。
2. 不用 ccswitch / cpa 反代理：不改配置文件或反代理來減少變數讓 codex 及其他 agent 支援不同請求頭來調用其他模型，因官方 harness 搭配預設模型也是 agent 能力的一環。
3. reasoning_effort 都 high：低 effort 可能讓失敗來自 LLM under-utilization 而非 harness 設計。

二、呈現方式

PPT 錄影。

三、實作步驟

1. 設計 20 個 agentic task (rename / add tests / add logging / simple bug fix)。
2. 6 configs × 20 tasks 跑，記錄 tool 序列、reasoning trace、結果。
3. 對 4 harness 實作 M1–M4 並執行 ablation。
4. 計算 Jaccard、disagreement，2×3 factorial 分析，五面向矩陣。

四、研究方法

(一) Harness × 模型 配置 (2×3 partial factorial)

	Claude Code	OpenCode	Hermes	Codex CLI
Haiku 4.5	✓ anchor	✓	✓	✗
GPT-5.4-mini	✗	✓	✓	✓ anchor

共 6 configs，思考強度=high。橫向 = harness effect、縱向 = model effect、分離交互作用。

(二) xAI Attribution 方法 (白箱 4 種)

1. M1 系統提示 ablation：移除 / 替換 system prompt 段落。
2. M2 工具定義擾動：rename、改 docstring、移除特定 tool。
3. M3 行為 counterfactual swap：改寫 task input。
4. M4 計畫迴圈 trace：harness hook 攔截 reasoning step。

(三) 指標

指標：Jaccard、disagreement、success 關聯。

五、預期結果

1. RQ1：4 種 xAI 方法對同一 decision point 的 attribution 是否一致？不一致比例與 pattern？
2. RQ2：高 disagreement 是否與任務失敗正向關聯？可否作 governance trigger？
3. RQ3：harness 主效應、model 主效應、交互作用對 tool 選擇差異如何解釋？
4. RQ4：能否轉化 agent-card 模板（fidelity / stability / robustness / actionability / governability）？